

Прогноз расходов муниципалитетов

Проверенные результаты и границы применимости | 7 октября 2026

1. Сравнение с настоящим Prophet

В GitHub Actions выполнены три варианта Prophet на одной фиксированной выборке 100 муниципалитетов. Таблица показывает MAE в рублях; меньше означает лучше. Исследуется категория «Все категории». Это наш воспроизводимый ретроспективный тест, а не оценка закрытой модели Сбера.

Метод	1 мес.	3 мес.	6 мес.	12 мес.
V3-hedge	710.31	971.55	1159.48	-
V3	852.90	1078.95	1224.74	-
V4-diversified	772.42	1019.43	1186.82	-
Prophet auto	1533.23	1831.29	2229.49	2783.25
Prophet log + Fourier 4	1632.32	1766.58	2170.70	15136.52
Prophet log + месяцы	1075.02	2162.00	4022.66	674723.61
Сезонный наивный	4446.11	4452.67	4369.32	4941.30
Национальный резерв	-	-	-	1575.06

На 1, 3 и 6 месяцах сравниваются 1000, 800 и 500 одинаковых пар соответственно. На 12 месяцах доступны только 100 пар с одной датой прогноза; V3/V4 там не определены. Национальный резерв - отдельный метод.

Снижение MAE у V3-hedge относительно каждого Prophet

Контрольная модель	1 мес.	3 мес.	6 мес.
Prophet auto	53.7%	46.9%	48.0%
Prophet log + Fourier 4	56.5%	45.0%	46.6%
Prophet log + месяцы	33.9%	55.1%	71.2%

Все три настройки Prophet заданы до серверного расчёта и опубликованы вместе. Неудачные прогнозы и варианты не удалялись. Выигрыш на уже изученной истории не гарантирует сохранения результата на новых данных.

Метод и протокол проверки

2. Почему выбрана V3-hedge

Модель объединяет локальную сезонную компоненту и общую динамику панели 2016 муниципалитетов с равными весами. Для общего темпа роста используются муниципальные окна 2 и 6 месяцев и национальное окно 2 месяца. Затем добавляется поправка по двум уже наблюдаемым ошибкам. Обучение поправки в каждой дате использует только завершившиеся прогнозы.

V4-diversified и robust-filtered-feedback проверены как улучшения. Более низкая ошибка отдельного окна не перенеслась на все проверки. V3-hedge выбран для устойчивого рабочего варианта по расширенным ретроспективным окнам; это исследовательский выбор после просмотра истории.

3. Одинаковые цели, разные способы использования информации

История муниципальных данных: январь 2023 - декабрь 2024. Выборка оцениваемых рядов фиксирована (seed=0). На $h=1$ используются origins февраль-ноябрь 2024; на $h=3$ февраль-сентябрь; на $h=6$ февраль-июнь. Для $h=12$ origin - декабрь 2023.

Панельная модель видит прошлое всей панели; Prophet обучается отдельно на каждом ряду. Это сравнение методов, а не одинакового набора признаков. Национальные ряды обрезаются по месяцу наблюдения, но исторические версии публикаций отсутствуют. Отбор полных рядов также ретроспективный.

Prophet: auto; логарифм и Fourier порядка 4; логарифм и 11 индикаторов месяца. У последних двух changepoint_prior_scale=0.01, у индикаторов prior_scale=0.1. Недельная и дневная сезонность отключены. Отрицательные прогнозы ограничиваются нулём. Горизонт означает значение месяца $t+h$, а не сумму за период.

4. Высокий R^2 уровня не означает точный прогноз роста

R^2 логарифмического годового роста у V3-hedge: $h=1$ 0.522; $h=3$ 0.090; $h=6$ -0.201. На шести месяцах показатель отрицательный. Поэтому малую MAE относительно Prophet нельзя превращать в заявление о надёжном долгосрочном прогнозе темпов роста.

12-месячный резерв умножает прошлогоднее муниципальное значение на доступный национальный годовой коэффициент. Только одна дата проверки не позволяет убедительно оценить его устойчивость.

Структурные изменения и новости

5. Разделяем обнаружение и упреждение

Исправлена разметка событий: масштаб определяется по прошлому, сезонное эхо ищется только назад, соседние события подавляются причинно. Событие подтверждается через два месяца; метки будущих событий для горизонта 3 месяца созревают через пять. Неизвестные метки исключаются из обучения и оценки.

Старая разметка меняла 214-523 созревшие метки при добавлении будущих данных. После исправления на всех проверенных origins изменений нет. Это устраняет найденную проблему созревания, но не доказывает отсутствие любых возможных утечек.

Задача / метод	AP	Precision	Recall
Обнаружение: BOCPD	0.4123	0.445	0.373
Обнаружение: jump	0.4065	0.450	0.377
Обнаружение: logistic-base	0.4655	0.545	0.457
Упреждение: jump	0.0552	0.105	0.128
Упреждение: logistic-base	0.0264	0.030	0.037

Здесь используются все 2016 муниципалитетов, отдельно от выборки Prophet. Бюджет сигналов фиксирован: 40 муниципалитетов в месяц (около 2%). AP - average precision. Logistic-base уменьшает ложные тревоги обнаружения до 0.903 на 100 ряд-месяцев; у jump 1.091. Это обнаружение уже начавшегося события, а не его предотвращение.

Для будущих шоков лучший из показанных простых методов имеет precision лишь 10.5%; большинство предупреждений ложные. Надёжное упреждение и предотвращение экономических шоков не продемонстрированы.

6. Новости проверены, но не улучшают итог

После дедупликации есть 516 публикаций; консервативно сопоставлены 104 публикации с 77 муниципалитетами. Для 107 одноимённых рядов география не выдумывается. Используются публикации, доступные по дате, и признаки планируемых событий. Неполный архив и отсутствие официального crosswalk ограничивают анализ.

Локальные новости почти не меняют AP обнаружения (0.4655 -> 0.4657) и не дают полезного упреждения. Национальная новостная поправка после исправления псевдорепликации ухудшает exact MAE до 1069.85 руб. Новости оставлены как исследовательский модуль; в основной прогноз не включены.

Воспроизводимость и готовность

7. Что сохранено для проверки

В репозитории сохранены фактические прогнозы на всех 2400 парах, метрики, сравнения, SHA-256 входов и исходников, версии пакетов и ссылка на серверный запуск. Агрегатор отклоняет неполные результаты, разные пары, несовпадающие источники и версии. Четыре проверки протокола прошли локально и в Actions.

Исходный commit расчёта: 81e49b355f2a745fbee30eb091362a2f199a108. GitHub Actions run: 37579679215. Python 3.11.16; NumPy 2.4.6; pandas 2.3.3; Prophet 1.5.0; cmdstanpy 1.3.0.

Основные файлы: PROPHET_COMPARISON.md - протокол; outputs/prophet_verified/ - подтверждения; IMPROVEMENT_REPORT.md - аудит моделей и шоков; benchmarks/contest_prophet.py - расчёт; benchmarks/summarize_prophet_ci.py - независимый пересчёт метрик по сохранённым прогнозам.

8. Что остаётся неподтверждённым

Новая независимая временная выборка отсутствует: доступная история уже использовалась в исследовании. На длинных горизонтах мало дат. Современная выгрузка может содержать ревизии; календарь фактических публикаций не восстановлен. Преимущество над моделью организаторов не установлено: её прогнозы на этих же парах не предоставлены.

TimesFM 2.5 присутствует в историческом эксперименте репозитория и тогда не улучшала точечный прогноз. В текущем серверном запуске foundation-модели не переобучались и не проверялись заново. Chronos-2 не запускалась. Старые оценки покрытия интервалов нельзя выдавать за подтверждённые на новом протоколе.

Экспорт из декабря 2024 создаёт исторический пример прогнозов на 2025 год, а не актуальный прогноз из октября 2026. Для рабочего применения нужны свежие муниципальные данные и проверка фактической доступности национальных показателей.

9. Формулировка для защиты

Предлагается прозрачная панельная модель с воспроизводимым сравнением против трёх вариантов Prophet, причинной разметкой сдвигов и отдельным анализом новостей. Сильная сторона - качество краткосрочного прогноза и обнаружение уже начавшихся изменений. Основные открытые задачи - независимая проверка, длинные горизонты и полезное раннее предупреждение.